Assignment Machine Learning

2802421242 - Ken Nicholas Latif

1. Exploratory Data Analysis (EDA)

Pada tahap ini, dilakukan eksplorasi data untuk mengetahui karakteristik data sebelum dilakukan preprocessing data. Analisis yang dilakukan mencakup:

- Informasi dataset (shape, info, describe)
- Analisis distribusi target (Fraudulent)
- Cross tabulation antar fitur kategorikal dengan target
- Analisis korelasi antar fitur numerik dengan target
- Deteksi outlier menggunakan boxplot

1.1 Informasi Dataset

Dataset terdiri dari 51.000 baris dengan 12 kolom.

Tabel 1.Daftar Kolom Dataset

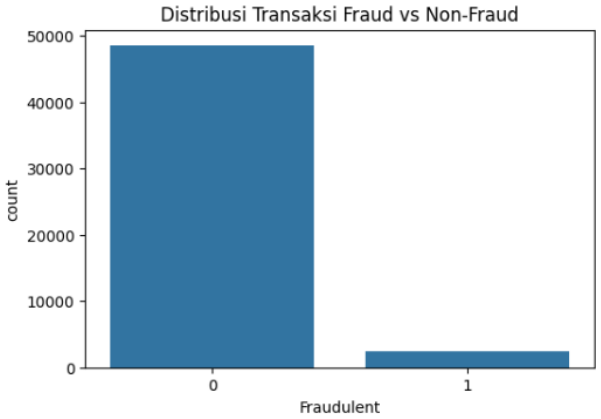
No	*Nama Kolom*	*Tipe Data*
1	Transaction_ID	Object
2	User_ID	Integer
3	Transaction_Amount	Float
4	Transaction_Type	Object
5	Time_of_Transaction	Float
6	Device_Used	Object
7	Location	Object
8	Previous_Fraudulent_Transactions	Integer
9	Account_Age	Integer
10	Number_of_Transactions_Last_24H	Integer
11	Payment_Method	Object
12	Fraudulent (Target)	Integer

Dataset terdapat missing value pada kolom: `Transaction_Amount`, `Time_of_Transaction`, `Device_Used`, `Location`, dan `Payment_Method`.

1.2 Distribusi Target (Fraudulent)

Target prediksi dalam dataset ini adalah kolom ‘Fraudulent’, yang terdiri dari 2 kelas:

- ‘0’ = Non-Fraud (transaksi normal)
- ‘1’ = Fraud (transaksi penipuan)



Gambar 1. Countplot Distribusi Target

Distribusi target menunjukkan ketidakseimbangan kelas (class imbalance) yang signifikan:

Tabel 2. Distribusi Target (Fraudulent)

Kelas	***Jumlah Transaksi***	***Persentase***
Non-Fraud (0)	48.490	95,03%
Fraud (1)	2.510	4,97%

Hanya sekitar 4,97% dari total transaksi (51.000) yang tergolong fraud. Ketidakseimbangan ini perlu ditangani saat proses modelling agar model machine learning tidak bias memprediksi semua transaksi sebagai non-fraud.

1.3 Cross Tabulation (Transaction Type vs Fraudulent)

Cross tabulation dilakukan untuk melihat jika ada hubungan antara jenis transaksi (Transaction_Type) dengan kejadian Fraud.

Tabel 3. Persentase Fraud per Tipe Transaksi

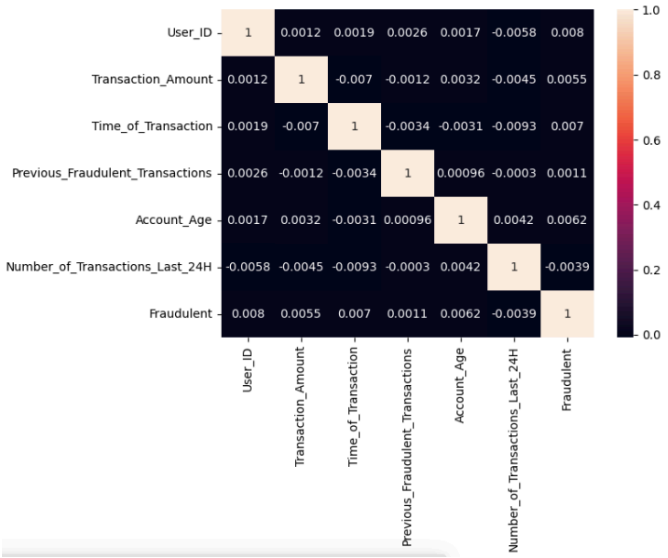
Transaction_Type	***Non-Fraud (%)***	***Fraud (%)***
ATM Withdrawal	95,35%	4,65%
Bank Transfer	95,19%	4,81%
Bill Payment	95,05%	4,95%
Online Purchase	94,81%	5,19%

POS Payment	94,99%	5,01%

Dari Tabel 3, persentase fraud pada setiap tipe transaksi relatif merata (4,65-5,19%). Tidak ada tipe transaksi dengan persentase fraud yang jauh lebih tinggi daripada tipe lainnya. Hal ini menunjukkan bahwa fitur `Transaction_Type` kemungkinan bukan merupakan fitur yang berpengaruh kuat dalam prediksi fraud dan non-fraud. Namun, fitur ini tetap disimpan untuk melihat pengaruhnya saat digabung dengan fitur lain saat pemodelan.

1.4 Korelasi Heatmap

Analisis korelasi dilakukan untuk mengetahui hubungan antar fitur numerik serta hubungannya dengan target (Fraudulent).



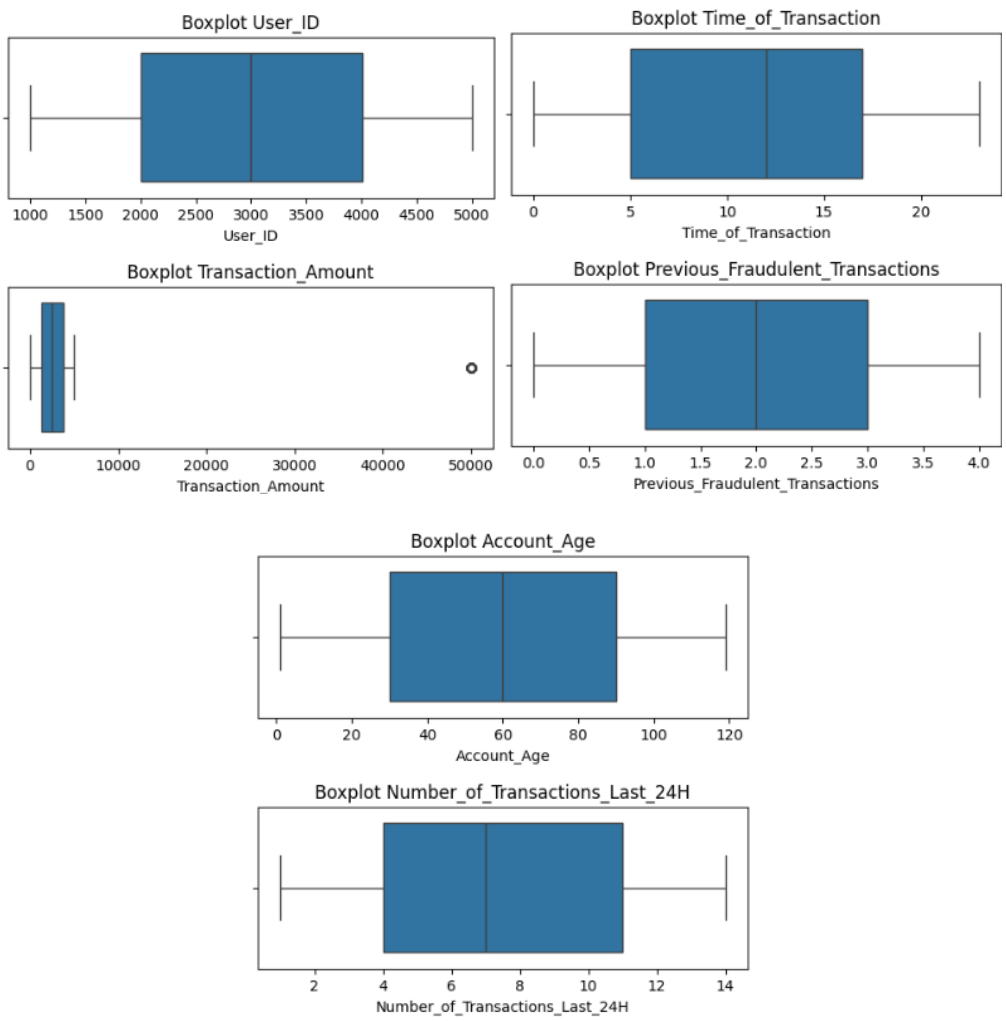
Gambar 2. Heatmap Korelasi Antar Fitur

Dari heatmap ditemukan bahwa:

- Semua nilai korelasi antar fitur numerik dengan target berada di bawah 0,01, yang menunjukkan tidak ada hubungan linier sama sekali.
- Tidak ada fitur yang dapat dipakai sendirian untuk langsung menebak target Fraudulent.
- Tidak ada fitur yang redundan, sehingga data aman untuk pemodelan.

1.5 Deteksi Outlier

Deteksi outlier dilakukan menggunakan boxplot pada setiap fitur numerik untuk mengidentifikasi nilai-nilai ekstrem yang berpotensi mengganggu performa model.



Gambar 3. Boxplot Fitur Numerik

Dari boxplot, ditemukan bahwa fitur `Transaction_Amount` memiliki banyak outlier, sedangkan fitur numerik lainnya tidak ada outlier.

2. Data Preparation

Pada tahap ini, dilakukan pembersihan dan persiapan data sebelum ke tahap modelling. Langkah yang dilakukan mencakup:

1. Drop kolom tidak berguna
2. Mengatasi missing value
3. Mengatasi outlier
4. Encoding fitur kategorikal
5. Train-test split
6. Scaling

2.1 Drop Kolom Tidak Berguna

Kolom `Transaction_ID` dan `User_ID` dihapus karena bersifat unik per transaksi dan tidak memiliki pola yang bisa dipelajari algoritma untuk prediksi fraud dan non-fraud.

2.2 Mengatasi Missing Value

Missing value ditemukan pada kolom numerik (Transaction_Amount, Time_of_Transaction) dan kategorikal (Device_Used, Location, Payment_Method). Fitur numerik diisi dengan median untuk menghindari pengaruh outlier, sedangkan fitur kategorikal diisi dengan modus agar distribusi data tetap terjaga.

2.3 Mengatasi outlier

Dari hasil deteksi boxplot pada tahap EDA, outlier hanya ditemukan pada fitur 'Transaction_Amount'. Untuk menjaga jumlah data kelas minoritas (fraud), outlier hanya dihapus dari kelas Non-Fraud (0). Outlier pada kelas Fraud (1) sengaja dipertahankan karena nilai ekstrem tersebut merupakan salah satu ciri-ciri penipuan.

Metode yang digunakan untuk mengatasi outlier adalah metode Interquartile Range (IQR), dimana:

$$IQR = Q3 - Q1$$

$$lower = Q1 - 1.5 * IQR$$

$$upper = Q3 + 1.5 * IQR$$

Sebanyak 476 outlier (dari kelas non-fraud) berhasil dihapus, sedangkan fitur lainnya tidak memiliki outlier.

2.4 Encoding (One-Hot Encoding)

Fitur kategorikal (`Transaction_Type`, `Device_Used`, `Location`, `Payment_Method`) diubah menjadi bentuk numerik menggunakan One-Hot Encoding dengan parameter `drop_first=True` untuk menghindari multikolinearitas antar kolom variabel.

2.5 Train-Test Split

Dataset dibagi menjadi data training (80%) dan data testing (20%) menggunakan `train_test_split` dengan parameter `stratify=y` untuk menjaga distribusi kelas fraud dan non-fraud tetap seimbang pada data training dan data testing.

Hasil split:

- **Data training:** 40.419 data
- **Data testing:** 10.105 data
- **Jumlah fitur:** 23

2.6 Scaling (StandardScaler)

Setelah proses train-test split, dilakukan normalisasi menggunakan StandardScaler (Z-score normalization) untuk menyamakan rentang nilai antar fitur. Scaling dilakukan setelah split untuk mencegah data leakage, sehingga informasi dari data testing tidak ikut mempengaruhi proses normalisasi selama proses training.

3. Modelling

Pada tahap ini, dilakukan pelatihan model machine learning untuk memprediksi fraud dan non-fraud. Algoritma yang dievaluasi mencakup:

1. Random Forest (ensemble learning)
2. Logistic Regression (model linear)
3. Decision Tree (model berbasis pohon)
4. Naive Bayes (model probabilistik)

Logistic Regression, Decision Tree, dan Random Forest menggunakan parameter `class_weight='balanced'` untuk menangani class imbalance. Selain itu, Stratified K-Fold Cross Validation (5-fold) digunakan sebagai evaluasi awal untuk memastikan performa model stabil terhadap variasi data.

3.1 Random Forest Classifier

Random Forest adalah model berbasis ensemble learning yang menggabungkan konsep bagging dan random feature subsets. Bagging memastikan setiap pohon dilatih dengan data acak yang berbeda. Sedangkan random feature subsets membatasi jumlah fitur yang digunakan setiap pohon setiap pemisahan node. Kedua konsep ini membuat model lebih stabil dan tidak mudah overfitting.

Parameter yang digunakan mencakup :

- **max_depth=10** membatasi kompleksitas pohon (regularization)
- **min_samples_split=5** menetapkan batas minimal sampel untuk melakukan split (regularization)

- **min_samples_leaf=2** menetapkan batas minimal sampel di daun (regularization)
- **class_weight ='balanced'** memberikan bobot lebih pada kelas minoritas (fraud)
- **random_state=42** untuk memastikan hasil bisa direproduksi

Stratified K-Fold Cross Validation (5-fold) digunakan untuk mengevaluasi stabilitas model. Rata-rata F1-Score yang didapat dari 5-fold CV adalah 0,0724.

3.2 Logistic Regression Classifier

Logistic Regression adalah model berbasis linear yang digunakan untuk klasifikasi biner. Model ini bekerja dengan mempelajari hubungan linear antara fitur dan target, lalu mengubahnya ke dalam rentang probabilitas 0 hingga 1 menggunakan sigmoid.

Parameter yang digunakan mencakup :

- **C=1.0** untuk mengontrol penalti dan mencegah overfitting (regularization)
- **class_weight ='balanced'** untuk menangani class imbalance
- **random_state=42** untuk memastikan hasil bisa direproduksi
- **max_iter=1000** meningkatkan jumlah iterasi (dari default 100)

Stratified K-Fold Cross Validation (5-fold) digunakan untuk mengevaluasi stabilitas model. Rata-rata F1-Score yang didapat dari 5-fold CV adalah 0,0912.

3.3 Decision Tree Classifier

Decision Tree adalah model supervised learning berbasis pohon keputusan yang bekerja dengan memecah data menjadi cabang-cabang. Setiap cabang menerapkan aturan if-else hingga mencapai keputusan akhir di leaf node.

Parameter yang digunakan mencakup :

- **max_depth=10** membatasi kompleksitas pohon (regularization)
- **min_samples_split=5** menetapkan batas minimal sampel untuk melakukan split (regularization)
- **min_samples_leaf=2** menetapkan batas minimal sampel di daun (regularization)
- **class_weight ='balanced'** untuk menangani class imbalance
- **random_state=42** untuk memastikan hasil bisa direproduksi

Stratified K-Fold Cross Validation (5-fold) digunakan untuk mengevaluasi stabilitas model. Rata-rata F1-Score yang didapat dari 5-fold CV adalah 0,0906

3.4 Naive Bayes Classifier

Naive Bayes adalah model berbasis probabilistik berdasarkan Teorema Bayes yang mengasumsi setiap fitur independen satu sama lain. Model ini sering digunakan sebagai baseline karena kesederhanaannya.

Model ini menggunakan parameter default dari scikit-learn (GaussianNB) tanpa parameter tambahan. Stratified K-Fold Cross Validation (5-fold) digunakan untuk mengevaluasi stabilitas model. Rata-rata F1-Score yang didapat dari 5-fold CV adalah 0,0284

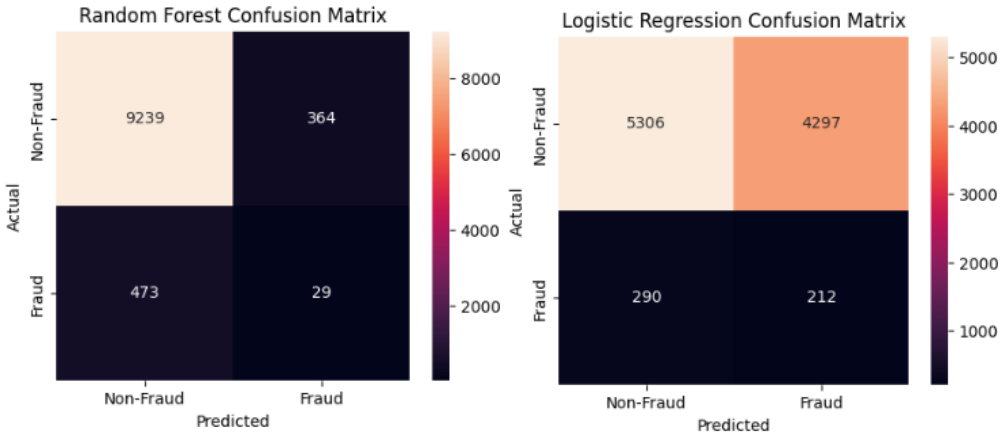
4. Evaluation

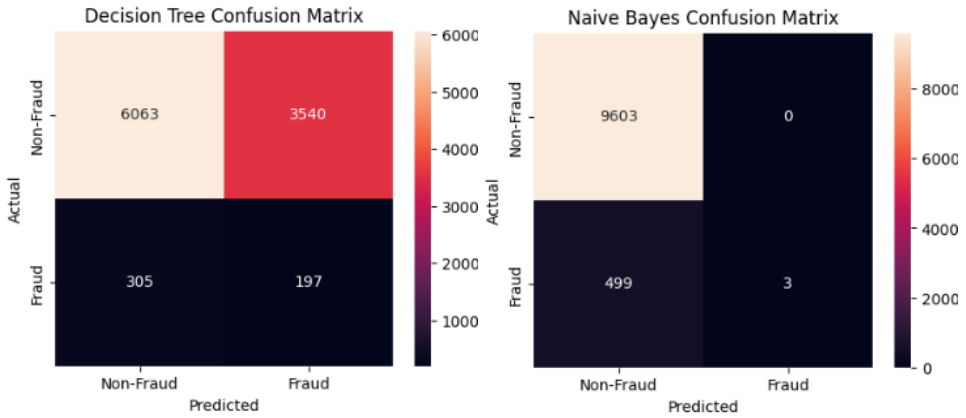
Pada tahap ini, dilakukan evaluasi performa keempat model yang telah di-training dengan data testing. Metrik yang dibandingkan mencakup akurasi, presisi, recall, F1-Score, dan confusion matrix.

4.1 Perbandingan Metrik Keempat Model

Tabel 4. Perbandingan Performa Model

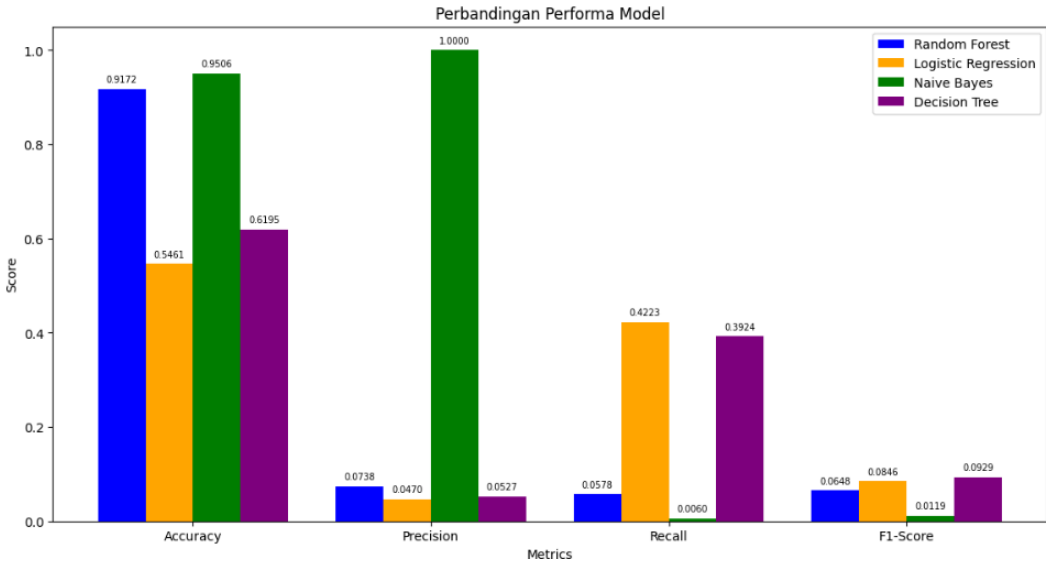
Model	***Accuracy***	***Precision***	***Recall***	***F1-Score***
Random Forest	91,72%	7,38%	5,78%	6,48%
Logistic Regresssion	54,61%	4,70%	42,23%	8,46%
Decision Tree	61,95%	5,27%	39,24%	9,29%
Naive Bayes	95,06%	100%	0,60%	1,19%





Gambar 4. Confusion Matrix Keempat Model

4.2 Visualisasi Perbandingan



Gambar 4. Perbandingan Performa Model

4.3 Analisis Hasil

Berdasarkan hasil evaluasi, Logistic Regression memiliki recall tertinggi sebesar 0,4223 (42,23%) yang berarti model ini mampu mendeteksi hampir setengah dari total transaksi fraud. Decision Tree di posisi kedua dengan recall 0,3924 (39,24%), diikuti Random Forest dengan recall 0,0578 (5,78%), sedangkan Naive Bayes hanya mencapai recall 0,0060 (0,6%). Untuk metrik precision, Random Forest tertinggi dengan 0,0738 (7,38%) namun recall-nya sangat rendah, artinya model ini jarang memprediksi fraud tetapi ketika memprediksi cenderung benar.

Akurasi tinggi pada Naive Bayes (95,06%) dan Random Forest (91,72%) bisa menyesatkan. Karena model cenderung menebak semua transaksi sebagai non-fraud mengingat adanya

class imbalance (fraud cuma sekitar 5%), namun gagal mengenali kelas fraud. Terbukti dari nilai recall pada Naive Bayes yang buruk (0,60%).

Dalam kasus deteksi fraud, fokus utama adalah pada metrik recall, karena kegagalan mendeteksi fraud lebih besar dibandingkan salah mencurigai transaksi normal (false alarm). Karena itu, Logistic Regression adalah model terbaik dari keempat model yang diuji untuk dataset ini.

5. Conclusion

Dari hasil eksperimen, dapat disimpulkan bahwa dataset yang digunakan memiliki class imbalance yang signifikan, di mana hanya sekitar 5% transaksi yang termasuk fraud. Kondisi ini membuat beberapa model cenderung bias dan memprediksi semua transaksi sebagai non-fraud.

Dari keempat model yang diuji, Logistic Regression memberikan performa terbaik dengan nilai recall tertinggi (42,23%). Dalam kasus deteksi fraud, recall menjadi metrik paling penting karena kegagalan mendeteksi penipuan berdampak lebih besar dibandingkan kesalahan memprediksi transaksi normal sebagai fraud.

Meskipun Random Forest dan Naive Bayes menunjukkan akurasi tinggi, nilai tersebut menyesatkan karena kedua model gagal mengenali fraud, terbukti dari recall yang sangat rendah (5,78% dan 0,60%). Karena itu, akurasi bukan metrik yang cocok untuk digunakan saat dataset memiliki class imbalance.

Secara keseluruhan, metrik performa model yang didapat rendah, namun hal ini cukup normal mengingat temuan pada tahap EDA yang menunjukkan kalau korelasi antar fitur dengan target sangat rendah.